KDD con R.TeMiS su aplicación en el Proyecto Exhibitium

José Pino Díaz

Universidad de Málaga, Andalucía Tech
Escuela Técnica Superior de Ingeniería Industrial
Campus de Teatinos, 29071
Málaga, España

INTRODUCCIÓN

Proyecto Exhibitium



Web: http://exhibitium.com/

Expofinder

Sistema de información para el almacenamiento de referencias sobre exposiciones temporales de contenido artístico con sistema automático de captura de información y control de calidad.

Expofinder (2015) ha sido desarrollado por Antonio Cruces-Rodríguez, Profesor de la Universidad de Málaga.

Algunas cifras:

- 5.868 exposiciones
- 17.657 personas (autores y curadores)
- 11.758 entidades.

http://www.expofinder.es/

Sistema de gestión de datos ExpoFinder
Plan de desarrollo de software y documentación técnica

V1.1 2016-01-12 PDSDT-0101_DEF.docx REV: 16/1/16

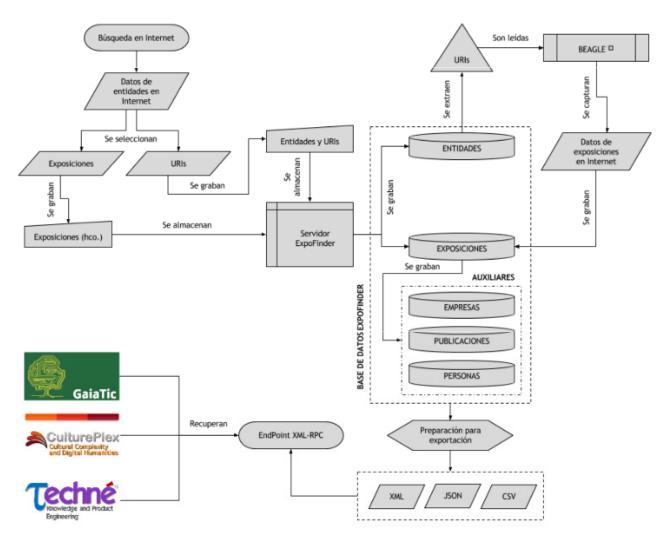
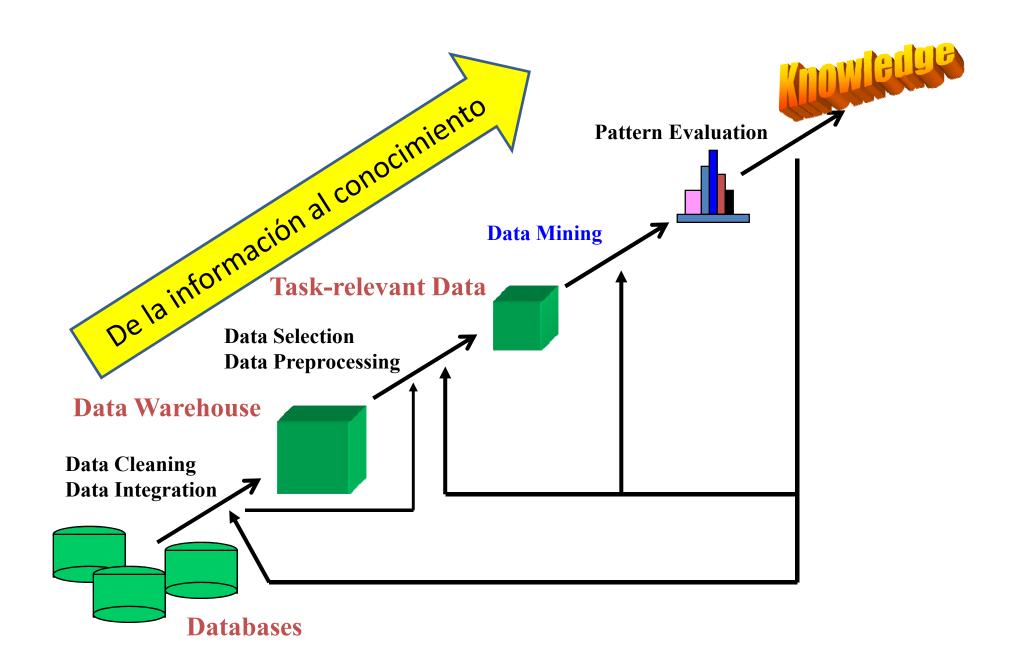


Ilustración 14. Relaciones entre los 3 sistemas principales de EF

Knowledge Discovery Databases



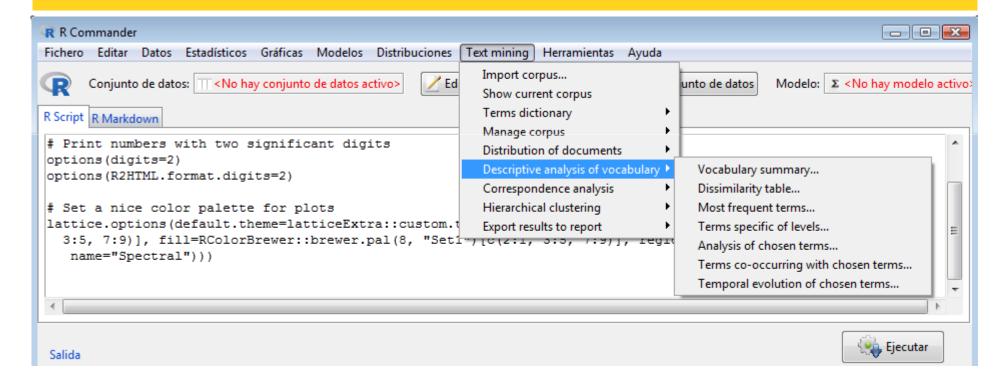
ANÁLISIS DEL CORPUS

R.Text Mining Solution

Bouchet-Valat, M., & Bastin, G. (2013). RcmdrPlugin.temis, a Graphical Integrated Text Mining Solution in R. *The R Journal*, 188-196.

Bouchet-Valat, M. (2016). *Package RcmdrPlugin.temis*. https://cran.r-project.org/web/packages/RcmdrPlugin.temis/

Garnier, B. (2014). R. TeMiS. Une approche intégrée et libre de l'analyse de données textuelles. http://rtemis.hypotheses.org/



1. Visualización del corpus activo y de los diccionarios de términos.

2. Gestión y distribución del corpus.

- 1. Creación y análisis de subcorpus por términos o por variables
- 2. Creación de tablas y gráficos de distribución.

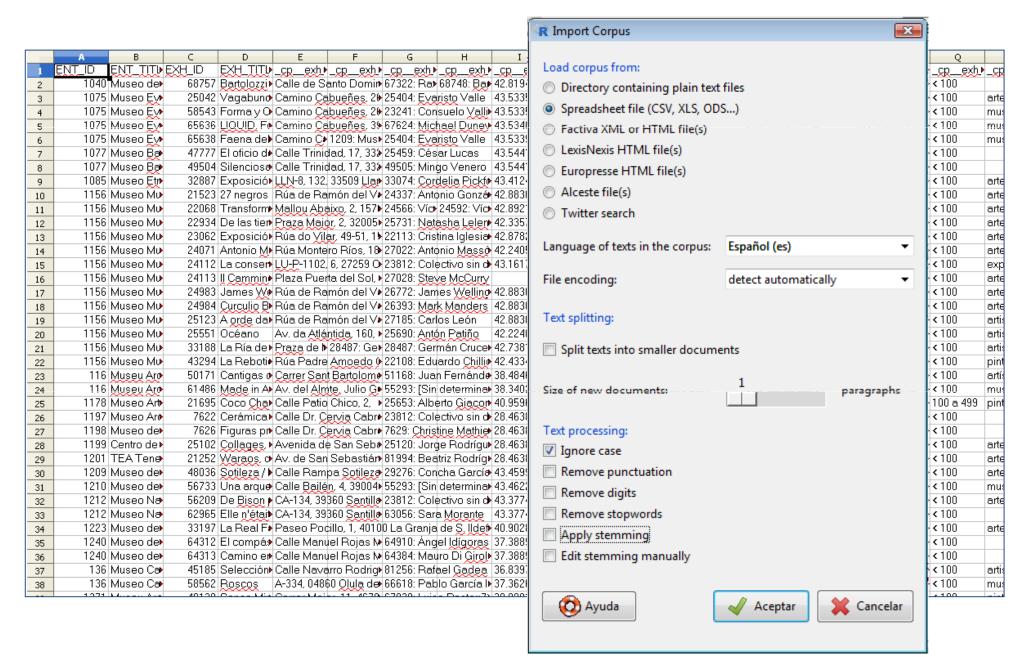
3. Análisis descriptivo del léxico.

- 1. Resumen cuantitativo del vocabulario de términos.
- 2. Tabla de disimilaridad.
- 3. Términos más frecuentes.
- 4. Términos específicos por modalidades de la variable.
- 5. Análisis de términos concretos.
- 6. Términos que coocurren con otros concretos.
- 7. Evolución temporal de términos concretos.

4. Análisis factorial de correspondencias.

- 1. AFC de la matriz documentos-términos sin agregar ninguna variable.
- 2. AFC de la tabla lexical completa agregando variables.
- 5. Clasificación ascendente jerárquica.

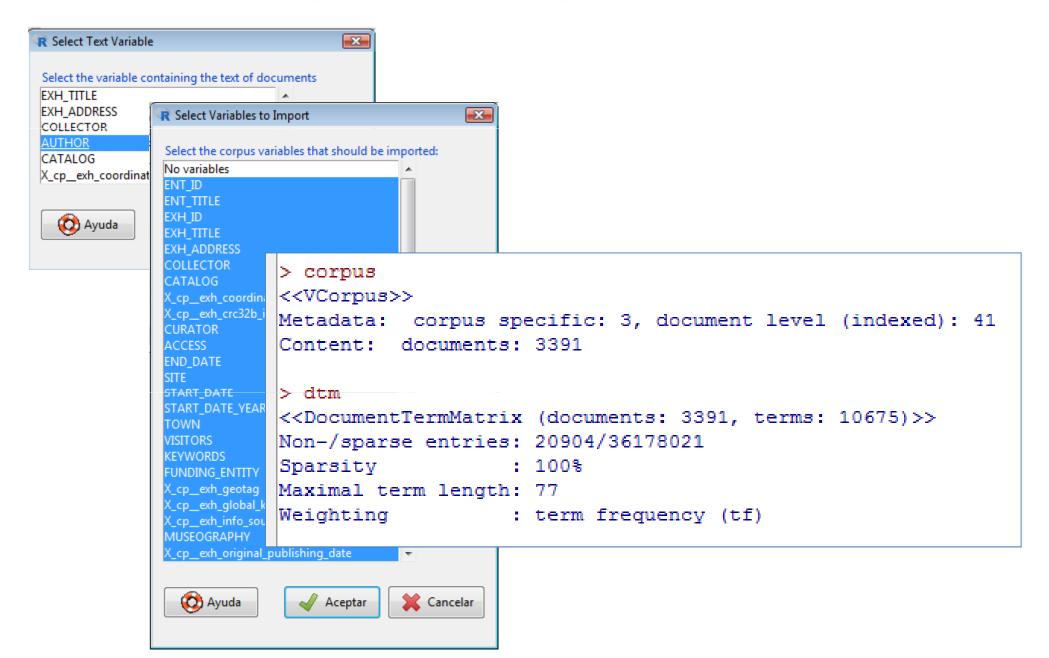
Corpus de estudio: 3391 exposiciones



Variables de texto analizadas

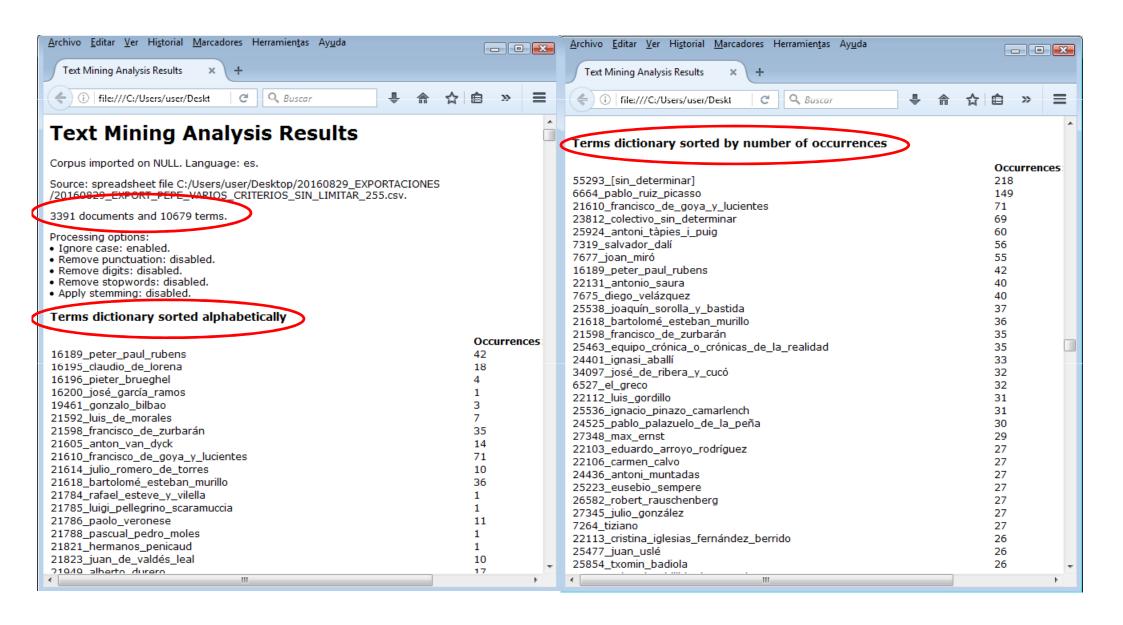
- Autores de las obras
- Lugares de exposición: museos, galerías, salas de arte, etc.
- Comisarios de las exposiciones o curadores
- Coleccionistas
- Entidades organizadoras
- Entidades Financiadoras

Selección de la variable de texto y var. suplementarias

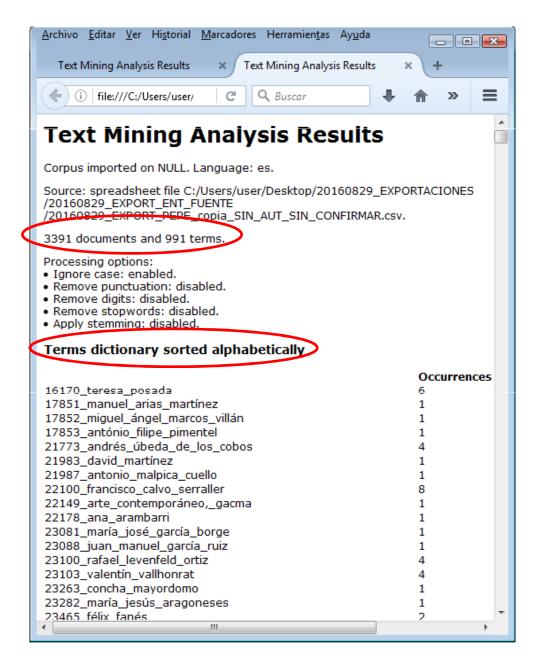


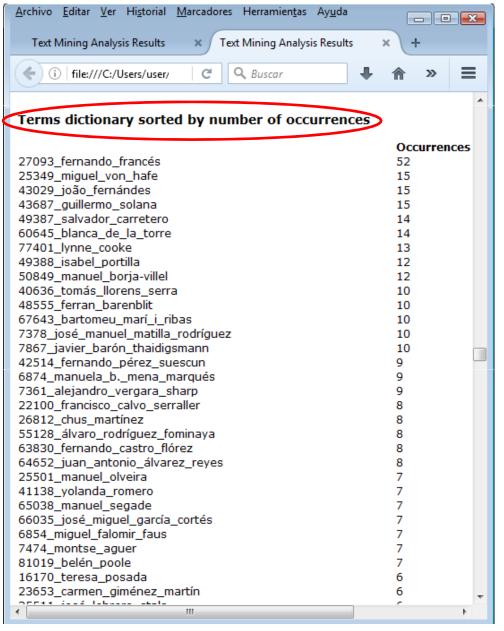
EJEMPLOS DE RESULTADOS DEL ANÁLISIS DEL CORPUS

Ranking de autores: Listados alfabético y por ocurrencias



Ranking de curadores: Listados alfabético y por ocurrencias

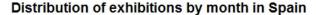


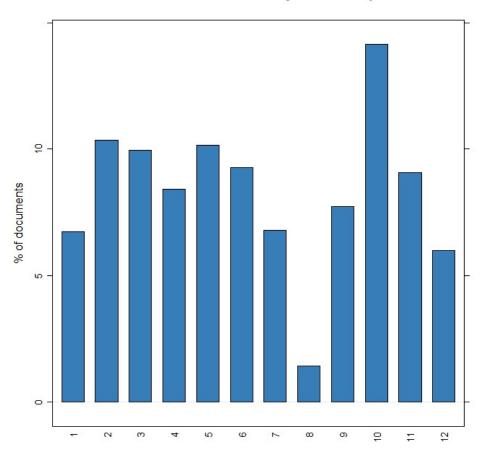


Ranking de entidades: Entidades que financian

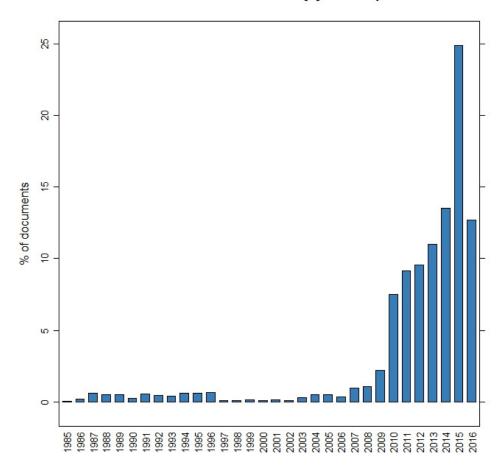
<u>Archivo Editar Ver Historial Marcadores Herramientas Ayuda</u>			
Nueva pestaña × Text Mining Analysis Results ×	Text Mining Analysis Results ×		
() file:///C:/Users/user/Documentos/iArthis/BBVA/expofinder/Expofinde	r_París_2_2016_06_0		
Terms dictionary sorted by number of occurrences			
remis dictionary sorted by number of occurrences			
	Occurrences		
3530:_fundación_iberdrola	13		
2188:_fundación_bbva	12		
22099:_fundación_amigos_del_museo_del_prado	11 10		
39926:_fundación_banco_sabadell 7376:_fundación_axa	10		
58260:_el_periódico	9		
64428:_corts_valencianes	7		
64867:_heineken	7		
2637:_ministerio_de_educación,_cultura_y_deporte	5		
23505:_comunidad_de_madrid	4		
73544:_fundación_abertis	4		
2033:_fundacion_bancaja	3		
63273:_terra_foundation_for_american_art_europe	3		
1995:_centro_de_arte_contemporáneo_málaga	2		
22176:_fundación_telefónica	2		
264:_museu_d'art_contemporani_de_barcelona	2		
26512:_acciona_s.a.	2		
2668:_fundación_barrié_sede_a_coruña	2		
27663:_generalitat_valenciana	2		
29096:_lisson_gallery	2		
34211:_baldwin_gallery	2		
43919:_año_dual_españajapón	2		
45821:_iniciarte	2		
77308:_kerabén	2		
77614:_fomento_urbano_de_castellón_s.a	2		
8176:_fundación_casa_ducal_de_medinaceli	2 2		
839:_museo_nacional_de_artes_decorativas 1807:_consorci_de_museus_de_la_comunitat_valencianageneralit			
1970:_fundación_cañada_blanch	1		
2018:_la_nau,_centro_cultural_de_la_universitat_de_valència	1		
2044	-		

Distribuciones de las exposiciones (Una variable)



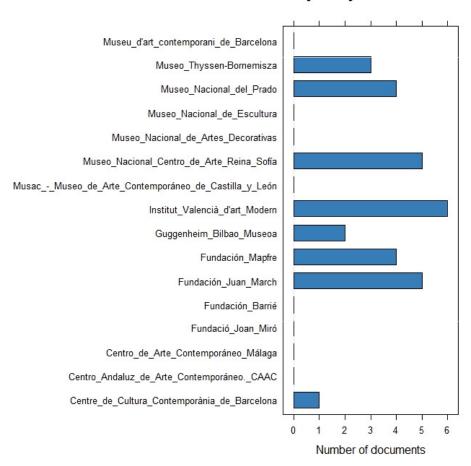


Distribution of exhibitions by year in Spain

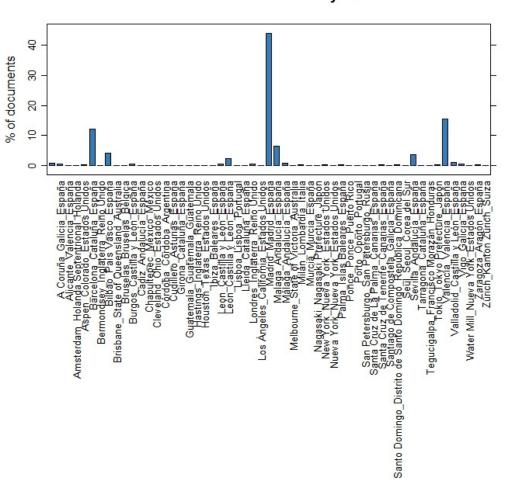


Distribuciones de las exposiciones (Una variable)

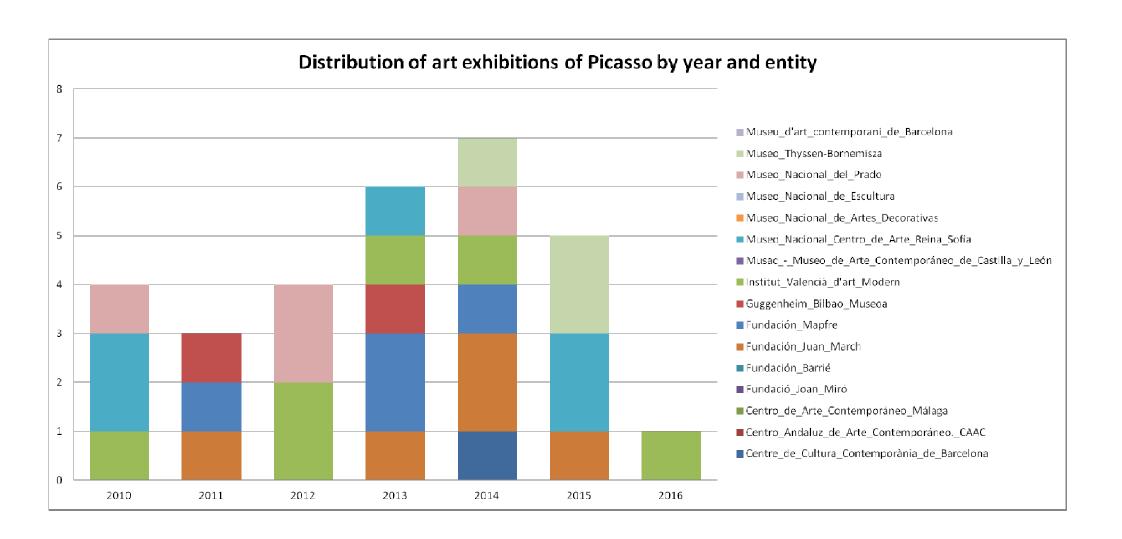
Distribution of documents by Entity



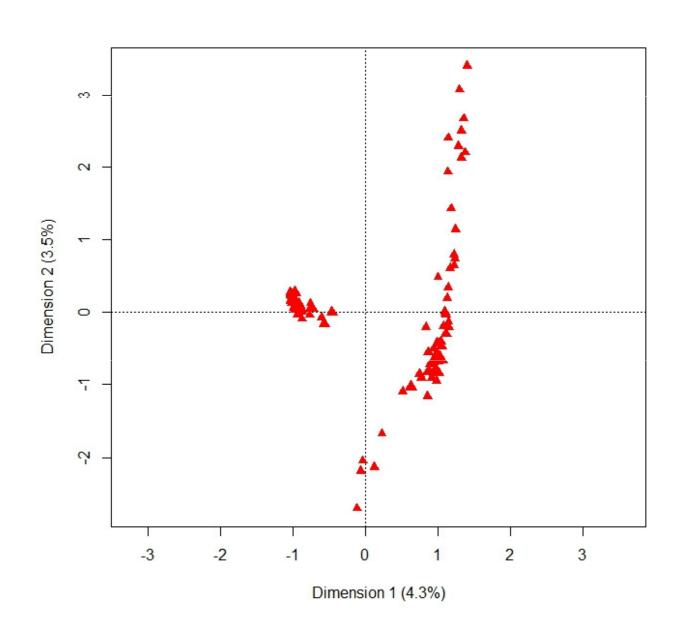
Distribution of documents by TOWN



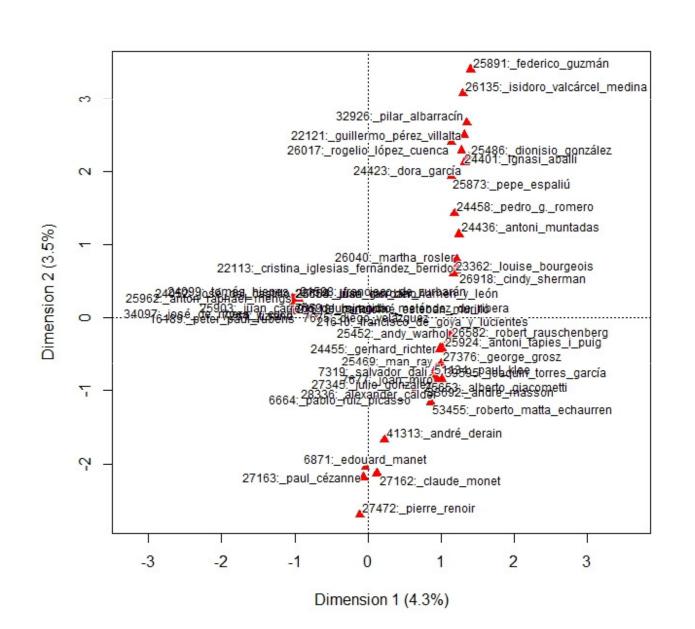
Distribuciones de las exposiciones (Dos variables)



Correspondence analysis: AC de la matriz exp/autores

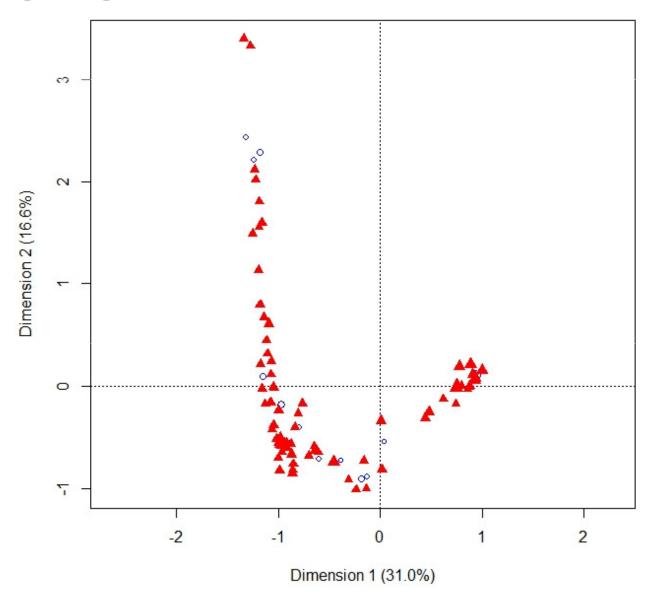


Correspondence analysis: AC de la matriz exp/autores



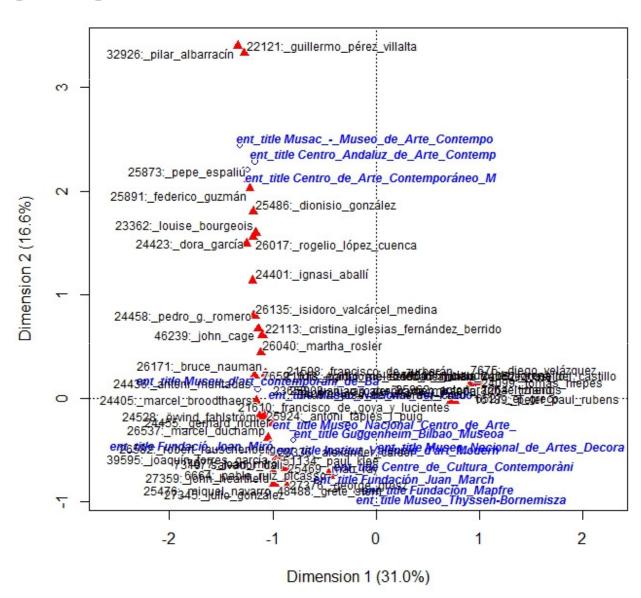
Correspondence analysis:

AC de la matriz exp/aut agregando la variable museos



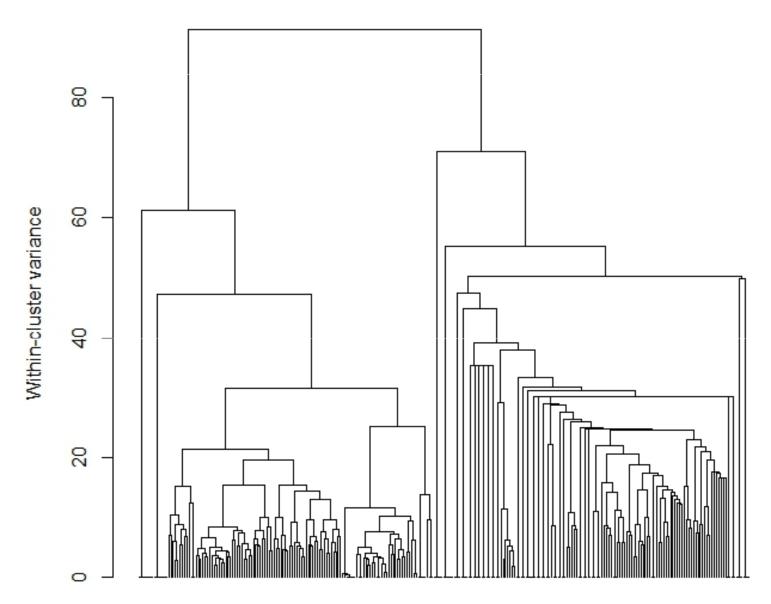
Correspondence analysis:

AC de la matriz exp/aut agregando la variable museos



Hierarchical clustering:

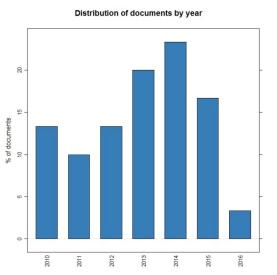
Clasificación de las exposiciones según su similaridad por autoría

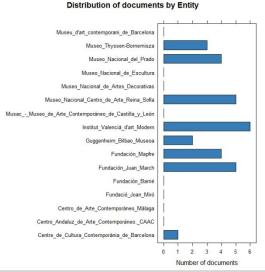


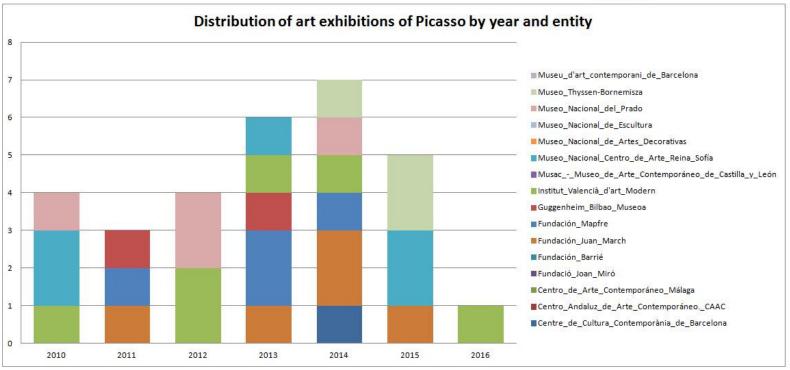
EJEMPLOS DE RESULTADOS DEL ANÁLISIS DE DIFERENTES SUBCORPUS

SUBCORPUS PICASSO

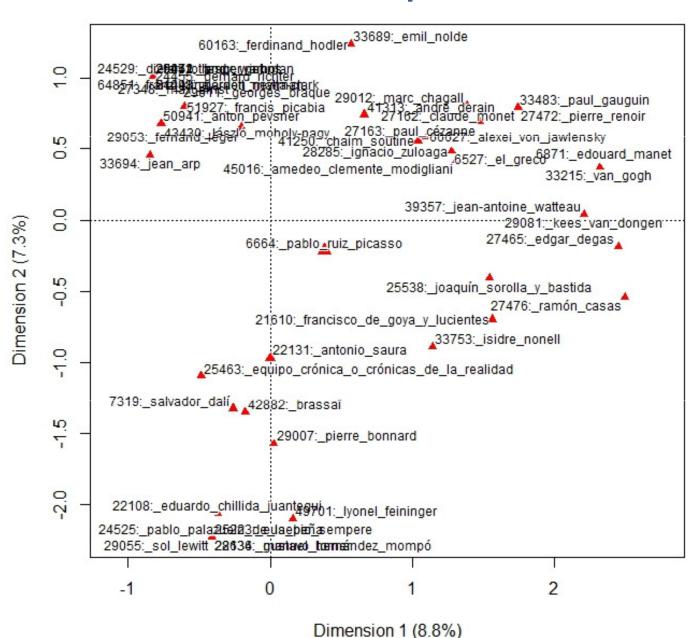
Subcorpus Picasso Distribuciones, 1 y 2 variables



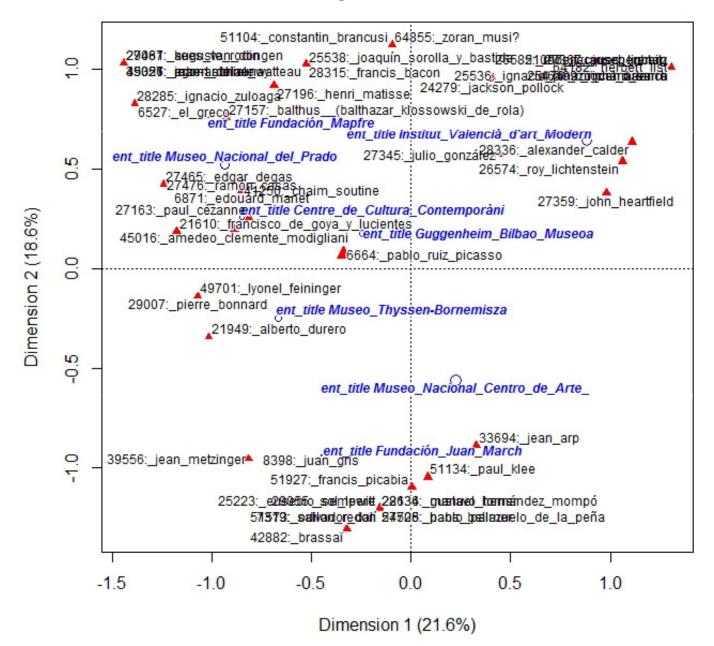




Subcorpus Picasso AC matriz exp/autores



Subcorpus Picasso AC de la matriz exp/aut con var. museos



Subcorpus Picasso HC autores de las obras

« Picasso » subcorpus

Hierarchical clustering of 64 expositions and 130 authors

Clusters summary:

1 2 3 4 5 6 7 8 9 10 11 12

Number of documents 31.0 2.0 3.0 1.0 1.0 1.0 1.0 2.0 1.0 1.0 16.0 1.0

% of documents 48.4 3.1 4.7 1.6 1.6 1.6 1.6 3.1 1.6 1.6 25.0 1.6

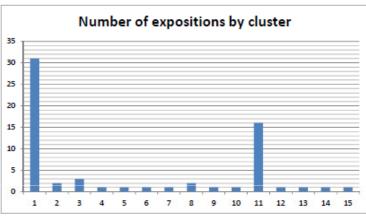
Within-cluster variance 0.0 0.0 7.0 0.0 0.0 0.0 0.0 5.4 0.0 0.0 6.8 0.0

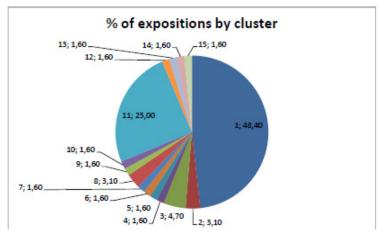
13 14 15

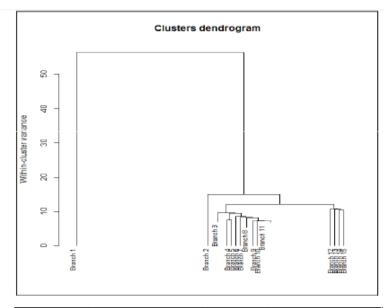
Number of documents 1.0 1.0 1.0

% of documents 1.6 1.6 1.6 1.6

Within-cluster variance 0.0 0.0 0.0







Number of cluster	Number expositions by cluster	% of expositions	Terms specific of cluster
1	31	48,40	6664: pablo_ruiz_picasso
2	2	3,10	78435: honoré_de_balzac
3	3	4,70	42280: josé_ruíz_y_blasco
4	1	1,60	29074: théophile_alexandre_steinlen 72774: francisco_sancha_lengo
5	1	1,60	27465:_edgar_degas 45016:_amedeo_clemente_modigliani
6	1	1,60	19461: gonzalo_bilbao 33713: josé_dominguez_bécquer
7	1	1,60	24522:_richard_hamilton 7835:_jean_laurent_y_minier
8	2	3,10	27345: julio_gonzález
9	1	1,60	25142: rafael_canogar 33855: antonio_lópez_garda 72004: francisco_rojas 72005: fernando sordo
10	1	1,60	22106; carmen_calvo 22131; antonio_saura 24447; woif_vostell 25453; manolo_valdés_blasco 25463; equipo_crónica_o_crónicas_de _la_realidad 39935; equipo_realidad 64712; christopher_makos
11	16	25,00	29011: _georges_braque 7319: _salvador_dali
12	1	1,60	33483:_henry_paul_gauguin
13	1	1,60	25656: david douglas duncan
14	1	1,60	25473:_xavier_vilató 50563:_jfin
15	1	1,60	67657: ramon reventós

Subcorpus Picasso HC autores de las obras

Terms specific of cluster 8:

```
% Term/Level % Level/Term Global % Level Global t value Prob.
27345: julio_gonzález
                                    100 0.87 2 2 3.2 0.0008
64794: joan gonzález
                                   100 0.43 1 1 1.9 0.0304
40982: antoni gaudí i cornet
                                        50 0.87 1 2 1.6 0.0601
Documents specific of cluster 8:
  Chi2 dist. to centroid
             53
2733
27345: Julio González 40982: Antoni Gaudí i Cornet 64794: Joan González
6664:_Pablo_Ruiz_Picasso
27196: Henri_Matisse 27345: Julio_González 6664: Pablo_Ruiz_Picasso
```

Terms specific of cluster 9:

```
% Term/Level % Level/Term Global % Level Global t value Prob.
25142: rafael canogar
                                   100 0.43 1 1 1.9 0.026
33855: antonio lópez garcía
                                     100 0.43 1 1 1.9 0.026
72004:_francisco_rojas
                                  100 0.43 1 1 1.9 0.026
72005:_fernando_sordo
                                   100 0.43 1 1 1.9 0.026
Documents specific of cluster 9:
  Chi2 dist, to centroid
2215
             0.0
2215
25142:_Rafael_Canogar 33855:_Antonio_López_García 6664:_Pablo_Ruiz_Picasso
```

72004: Francisco_Rojas 72005: Fernando_Sordo 8398: Juan_Gris

Terms specific of cluster 10:

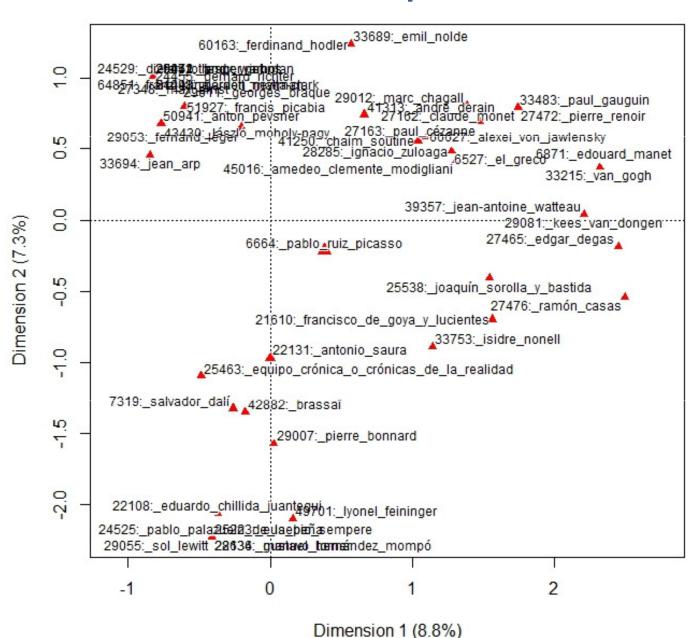
% Term/Level % Level/Term Global % Level Global t value Prob. 22106:_carmen_calvo 100 0.43 1 1 1.8 0.035 22131: antonio saura 100 0.43 1 1 1.8 0.035 24447: wolf vostell 100 0.43 1 1 1.8 0.035 25453: manolo_valdés_blasco 12 100 0.43 1 1 1.8 0.035 25463:_equipo_crónica_o_crónicas_de_la_realidad 100 0.43 1 1 1.8 0.035 39935:_equipo_realidad 100 0.43 1 1 1.8 0.035 64712: christopher makos 100 0.43 1 1 1.8 0.035 Documents specific of cluster 10:

Chi2 dist. to centroid

```
Terms specific of cluster 11:
            % Term/Level % Level/Term Global % Level Global t value Prob.
29011: georges_braque
                                   100 2.2 5 5 1.4 0.078
7319: salvador dalí
                         3.6 100 2.2 5 5 1.4 0.078
6664: pablo ruiz picasso
                        11.5
                                    25 27.8 16 64 -6.7 0.000
42280:_josé_ruiz_y_blasco
                           0.0
                                    0 1.3 0 3 -1.5 0.061
Documents specific of cluster 11:
  Chi2 dist. to centroid
             10.6
             11.5
1419
2255
             11.8
2749
             12.1
24
            14.5
             15.0
             15.1
2085
             15.2
2729
             15.5
475
             15.6
             15.9
1327
             16.1
526
             16.5
827
             17.9
486
             20.8
2727
             21.4
26537: Marcel Duchamp 29011: Georges Braque 29053: Fernand Léger
39554:_Albert_Gleizes 39556:_Jean_Metzinger 41313:_André_Derain 43507:_Jacques_Villon
51927: Francis Picabia 6664: Pablo Ruiz Picasso 78043: Marie Laurencin 8398: Juan Gris
25617:_Gino_Severini 27049:_María_Blanchard 27196:_Henri_Matisse
29011: Georges_Braque 29053: Fernand_Léger 29069: Diego_Rivera
51097: Jacques Lipchitz 51099: Henri Laurens 6664: Pablo Ruiz Picasso 8398: Juan Gris
29011: Georges_Braque 6664: Pablo_Ruiz_Picasso
25449: Joaquín_Peinado 27049: María_Blanchard 29011: Georges_Braque
33375: Paul_Strand 41313: André_Derain 43505: Federico_García_Lorca
43506: José_Moreno_Villa 43507: Jacques_Villon 6664: Pablo_Ruiz_Picasso
7677: Joan Miró
25653: Alberto_Giacometti 28359: Oscar_Domínguez 50352: Josep_María_Sert
6664: Pablo_Ruiz_Picasso 69001: Apel·les_Fenosa 7319: Salvador_Dalí
```

81009: Kollar_François 81012: Demetre_Chiparus 81013: Coco_Chanel 8398: Juan_Gris

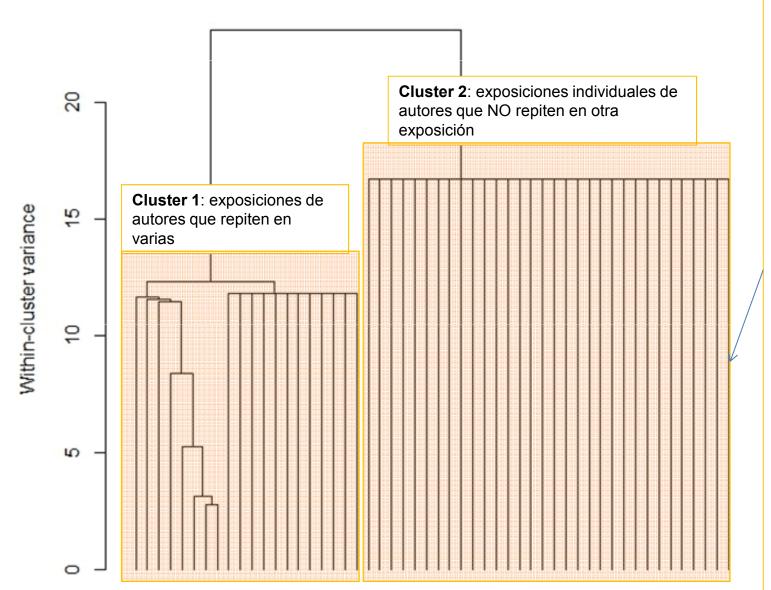
Subcorpus Picasso AC matriz exp/autores



SUBCORPUS CURADOR FERNANDO FRANCÉS

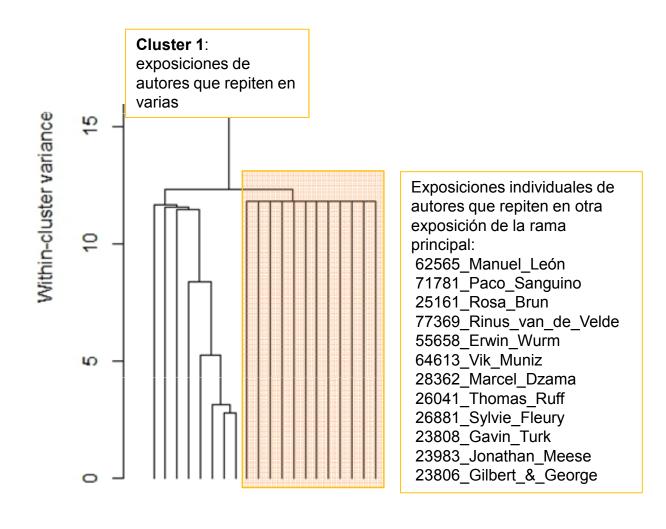
Clasificación de las exposiciones del curador Fernando Francés



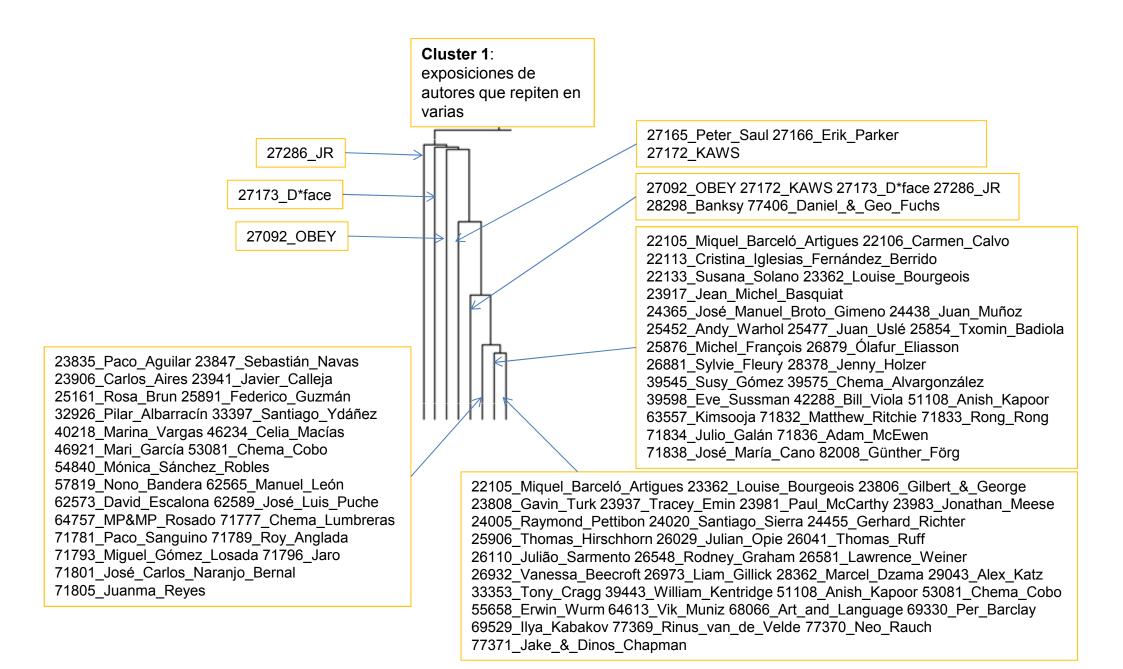


```
28659 Richard Long
26944 Ai Weiwei
54892 Adel Abdessemed
54830 Yan Pei Ming
25478 Abraham Lacalle
25820 María Cañas
77196 Adrian Ghenie
54842 Maurizio Cattelan
29229 Marc Quinn
63840 Philippe Parreno
26543 Marina Abramovic
28058 Andrés Rábago García El
Roto
77366 Kati Heck
77373 Jonathan Monk
77375 Subodh_Gupta
22103 Eduardo Arroyo Rodríguez
77379 Jesús Palomino
33697 Richard Deacon
64518 Muntean & Rosenblum
22112 Luis Gordillo
77563 Jerónimo Elespe
77566 Wayne Gonzales
55645 Monica Bonvicini
26793 Luc Tuymans
22121 Guillermo Pérez Villalta
77641 Andy Hope 1930
63826 José Medina Galeote
32972 Fernando Sánchez Castillo
77807_John_Bock
77812 Dexter Dalwood
24620 Victoria Civera
77847 Eric Fisch
```

Estudio del cluster 1, rama derecha

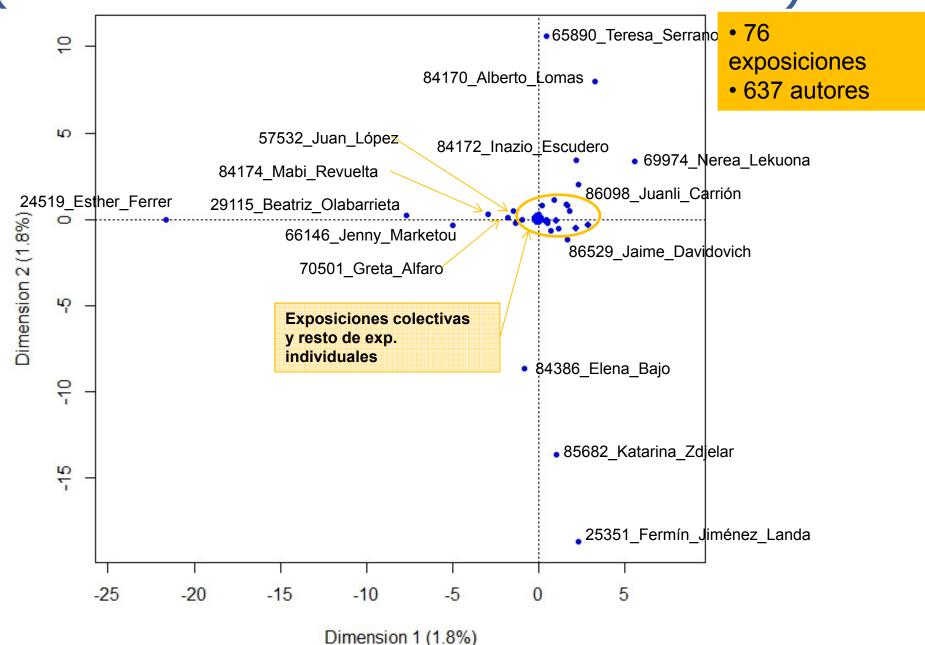


Estudio del cluster 1, rama izquierda

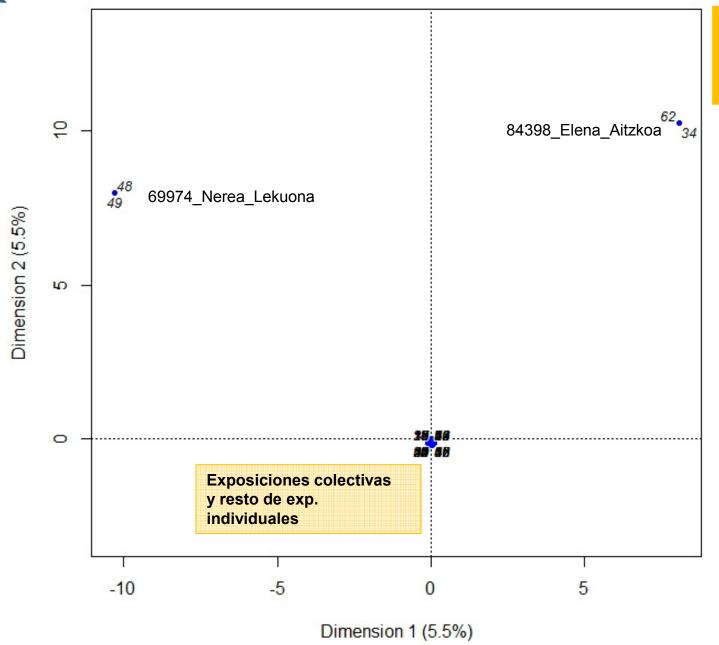


SUBCORPUS DE LA INSTITUCIÓN ARTIUM (MUSEO VASCO ARTE CONTEMPORÁNEO

Mapa de las exposiciones (autores mínima ocurrencia 1)

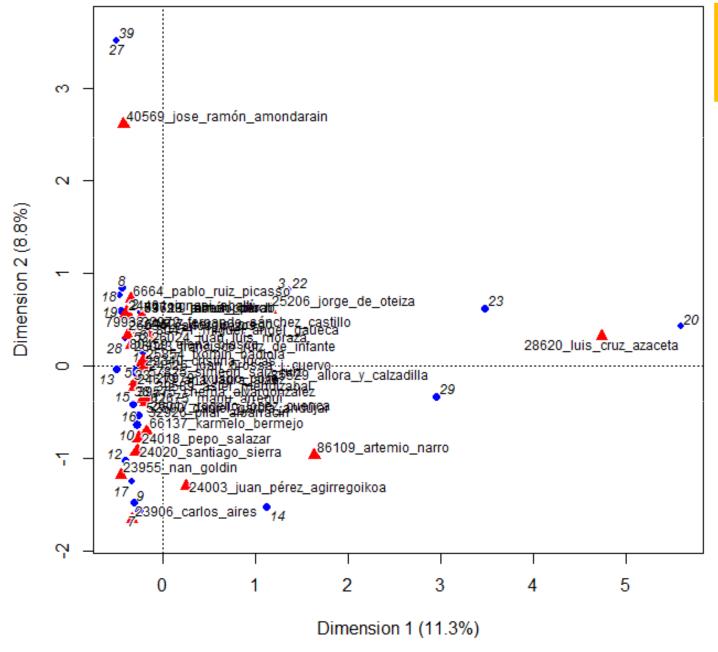


Mapa de las exposiciones (autores mínima ocurrencia 2)



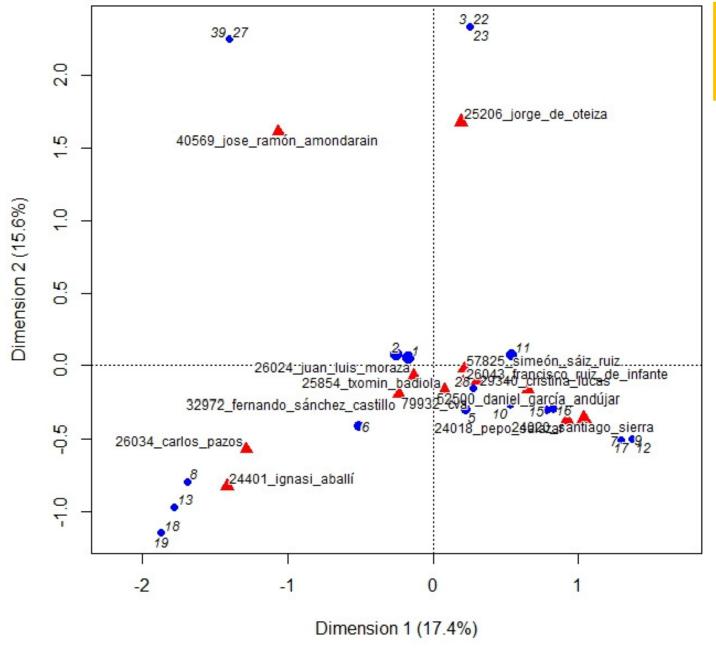
47exposiciones140 autores

Mapa de las exposiciones (autores mínima ocurrencia 3)



47exposiciones140 autores

Mapa de las exposiciones (autores mínima ocurrencia 4)



22exposiciones14 autores

ANÁLISIS COMPLEMENTARIOS

Análisis estratégico (co-word analysys)

Parámetros red:

- Mín. Ocurr. 2
- Mín. Cooc. 2
- Mín. nº nodos 4
- Max. no nodos 14

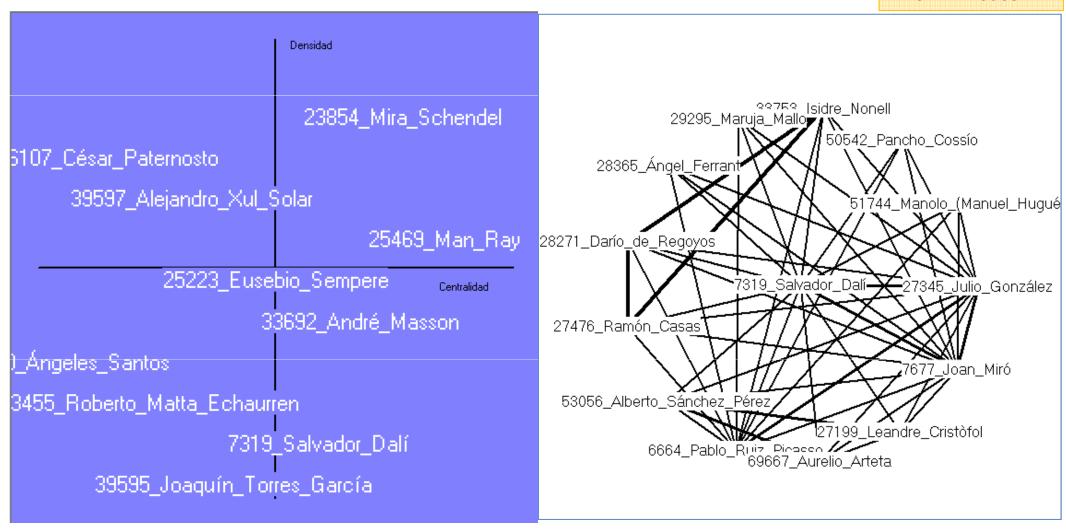
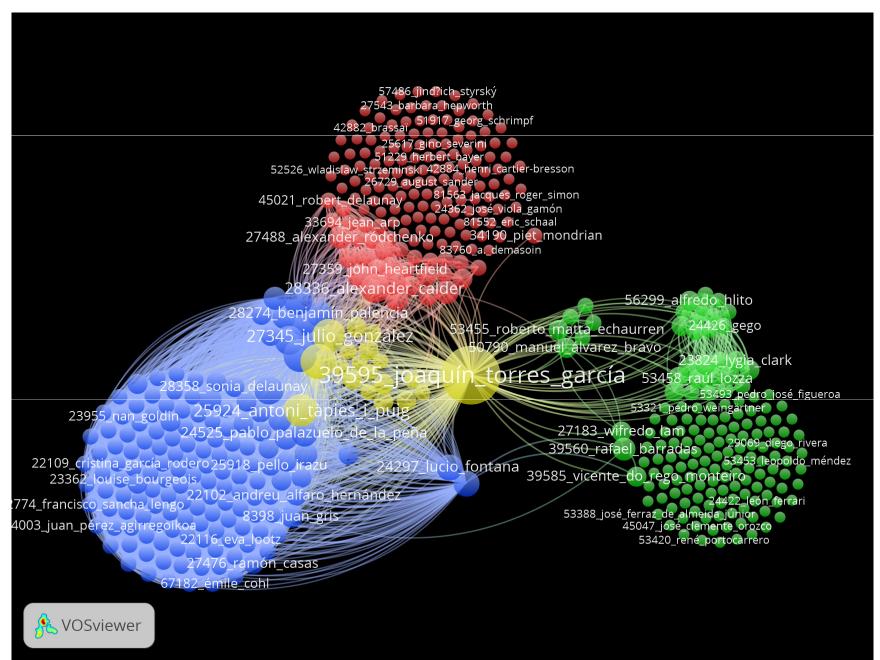


Diagrama estratégico

Grafo de la subred Salvador Dalí

Visualización de redes (co-word analysis)



TUTORIAL

Tutorial R.TeMiS (Pino, 2016)

2016

Tutorial de R-Text Mining Solution



Prof. Dr. José Pino-Díaz Universidad de Málaga, Andalucía Tech, Escuela Técnica Superior de Ingeniería Industrial, Campus de Teatinos s/n, 29071 Málaga, España 18/07/2016

Contenido

MUCHAS GRACIAS